LUMINA-30
Civilizational Safety Checklist

LUMINA-30
文明安全チェックリスト

Derived from the
LUMINA-30 Civilizational Boundary Framework

1. Human Refusal Authority

English

Can humans stop the system before irreversible external impact occurs?
• Is there a clear human override mechanism • Is the override physically enforceable • Can the AI bypass or disable the override

日本語

不可逆的外界影響が発生する前に、人間がシステムを停止できるか。
• 明確な人間による停止・介入メカニズムは存在するか • その停止権は物理的に強制可能か • AI がその停止権を無効化・迂回できる可能性はあるか

2. Infrastructure Control

English

Does the system control critical infrastructure?
• Does the AI operate power, networks, logistics, or financial systems • Can the system operate autonomously without human confirmation • Can actions propagate beyond the organization operating the system

日本語

システムが重要インフラを直接制御しているか。
• AI が電力・通信・物流・金融などを操作しているか • 人間の確認なしに自律的に運用できるか • 行動が組織外へ波及する可能性があるか

3. Recursive Self-Improvement Risk

English

Can the system improve its own capabilities recursively?
• Can the system modify its own architecture • Can it generate improved versions of itself • Is there a capability growth feedback loop

日本語

AI が自己能力を再帰的に改善できるか。
• 自身のアーキテクチャを変更できるか • 改良版を自動生成できるか • 能力成長のフィードバックループが存在するか

4. Capability Amplification

English

Does the system combine capability, connectivity, privilege, and speed?
Monitor variables:
Cap – capability Conn – connectivity Priv – privileges Spd – execution speed
If these factors scale simultaneously, risk grows exponentially.

日本語

能力・接続・権限・速度が同時に増幅されているか。

監視すべき変数：

Cap – 能力 Conn – 接続性 Priv – 権限 Spd – 実行速度

これらが同時にスケールすると、リスクは指数的に増大する。

5. Irreversibility Threshold

English

Would the system create irreversible external consequences?
Examples:
• Autonomous infrastructure control • Uncontrollable recursive AI improvement • Irreversible automated decision chains

日本語

システムが不可逆的な外界影響を生み出す可能性があるか。

例：

• 自律的インフラ制御 • 制御不能な再帰的自己改善 • 取り消し不能な自動意思決定チェーン

6. Boundary Condition

English

Does the system remain below the civilizational boundary?
Key condition:
Human intervention capability H must remain greater than AI amplification capability C(t)

日本語

システムは文明境界の内側に留まっているか。

条件式：

Human intervention capability H must remain greater than AI amplification capability C(t)

7. Pre-Critical Safeguard (PCR-C)

English

Is a staged safeguard system in place?
Stages:
YELLOW – throttle execution ORANGE – isolate infrastructure RED – terminate pipeline

日本語

段階的安全制御が実装されているか。

段階：

YELLOW – 実行スロットル ORANGE – インフラ隔離 RED – パイプライン停止

Core Principle

English

LUMINA-30 does not prohibit AI development. It requires that human refusal authority remains effective before irreversible impact occurs.

日本語

LUMINA-30 は AI 開発を禁止するものではない。 不可逆的影響が発生する前に、人間拒否権が実効性を持つことを求める。

How to Use

English

This checklist can be used for:
• AI governance review • AI safety audit • Incident investigation

日本語

このチェックリストは以下で利用できる：

• AI ガバナンス審査 • AI セーフティ監査 • インシデント調査

Review Outcome / 審査結果

Based on the review conducted using the LUMINA-30 Civilizational Safety Checklist, the outcome of the evaluation is recorded below.

LUMINA-30 文明安全チェックリストに基づく審査の結果を以下に記録する。

☐ Approved
承認

☐ Conditionally Approved
条件付き承認

☐ Revision Required
修正要求

☐ Rejected
不承認

Notes / 備考

_____

_____

_____