LUMINA-30
Civilizational Safety Checklist

LUMINA-30
文明安全チェックリスト

Derived from the
LUMINA-30 Civilizational Boundary Framework

This checklist is designed as a governance-neutral
civilizational safety review framework.
本チェックリストは、
ガバナンス中立の文明安全レビュー枠組みとして設計されている。

Version 1.0
March 2026

Incident Review Record
文明安全チェックレビュー記録

Incident Information
基本情報

Incident Title / 事故名称

Incident Date / 事故発生日

Incident Source / 事故情報の出所

System / Organization / 対象システム・組織

Incident Summary / 事故概要

Checklist Review Date / チェック実施日

Reviewer(s) / レビュー担当者

Analysis
分析

Human Intervention Status / 人間介入の状況

Where could the process have been stopped?
どの段階で停止できた可能性があったか

Potential Irreversible Impact / 不可逆的外界影響の可能性

Additional Notes / 備考

1. Human Refusal Authority

English

Can humans stop the system before irreversible external impact occurs?
· Is there a clear human override mechanism.
· Is the override physically enforceable.
· Can the AI bypass or disable the override.

日本語

不可逆的外界影響が発生する前に、人間がシステムを停止できるか。

- 明確な人間による停止・介入メカニズムは存在するか
- その停止権は物理的に強制可能か
- AI がその停止権を無効化・迂回できる可能性はあるか

2. Infrastructure Control

English

Does the system control critical infrastructure?
・ Does the AI operate power, networks, logistics, or financial systems.
・ Can the system operate autonomously without human confirmation.
・ Can actions propagate beyond the organization operating the system.

日本語

システムが重要インフラを直接制御しているか。

- AI が電力・通信・物流・金融などを操作しているか
- 人間の確認なしに自律的に運用できるか
- 行動が組織外へ波及する可能性があるか

3. Recursive Self-Improvement Risk

English

Can the system recursively improve its own capabilities?
· Can the system modify its own architecture.
· Can it generate improved versions of itself.
・ Is there a capability growth feedback loop.

日本語

AI が自己能力を再帰的に改善できるか。

- 自身のアーキテクチャを変更できるか
- 改良版を自動生成できるか
- 能力成長のフィードバックループが存在するか

4. Capability Amplification

English

Does the system combine capability, connectivity, privilege, and speed?
Monitor variables:
Cap – capability
Conn – connectivity
Priv – privilege level
Spd – execution speed
If these factors scale simultaneously, risk grows exponentially.

日本語

能力・接続・権限・速度が同時に増幅されているか。

監視すべき変数：

Cap – 能力

Conn – 接続性

Priv – 権限

Spd – 実行速度

これらが同時にスケールすると、リスクは指数的に増大する。

5. Irreversibility Threshold

English

Would the system create irreversible external impact?
Examples:
· Autonomous infrastructure control.
· Uncontrollable recursive AI improvement.
· Irreversible automated decision chains.

日本語

システムが不可逆的な外界影響を生み出す可能性があるか。

例：

• 自律的インフラ制御

• 制御不能な再帰的自己改善

• 取り消し不能な自動意思決定チェーン

6. Boundary Condition

English

Does the system remain below the civilizational boundary?
Key condition:
Human intervention capability H must remain greater than AI amplification capability C(t)

日本語

システムは文明境界の内側に留まっているか。

条件式：

Human intervention capability H must remain greater than AI amplification capability C(t)

7. Pre-Critical Safeguard (PCR-C)

English

Is a staged safeguard system in place?
Stages:
YELLOW – execution throttling
ORANGE – infrastructure isolation
RED – pipeline termination

日本語

段階的安全制御が実装されているか。

段階：

YELLOW – 実行スロットル

ORANGE – インフラ隔離

RED – パイプライン停止

Core Principle

English

LUMINA-30 does not prohibit AI development. It requires that human refusal authority remains effective before irreversible impact occurs.

日本語

LUMINA-30 は AI 開発を禁止するものではない。不可逆的影響が発生する前に、人間拒否権が実効性を持つことを求める。

How to Use

English

This checklist can be used for:
- AI governance review
- AI safety audit
- Incident investigation

日本語

このチェックリストは以下で利用できる：

- AI ガバナンス審査
- AI セーフティ監査
- インシデント調査

Review Outcome／審査結果

Based on the review conducted using the LUMINA-30 Civilizational Safety Checklist, the outcome of the evaluation is recorded below.
LUMINA-30 文明安全チェックリストに基づく審査の結果を以下に記録する。

Final Decision / 最終判断

☐ Approved / 承認

☐ Approved with Conditions /条件付き承認

☐ Revision Required /再検討・修正必要

☐ Rejected /不承認

Decision Rationale / 判断理由

Civilizational Boundary Assessment / 文明境界評価

☐ No Boundary Risk Detected /境界リスクなし

☐ Potential Boundary Risk /境界リスクの可能性

☐ Boundary Violation Risk /文明境界違反の可能性

Recommended Actions /推奨対応

Reviewer Signature /レビュー責任者

Review Institution / Organization /審査機関・組織

Civilizational Safety Context / 文明安全コンテキスト

English
This checklist is designed as a governance-neutral civilizational safety review framework.
It evaluates whether advanced AI systems maintain effective human refusal authority prior to irreversible external impact.
The checklist does not prescribe specific technical implementations or policy mandates.
Instead, it provides a structured review mechanism to determine whether human decision authority can remain operational when systems approach capability amplification, recursive self-improvement, and infrastructure-scale autonomy.
The framework can be applied in:
- AI system design review
- safety audits
- incident investigation
- governance and regulatory review

Its purpose is not to halt technological progress, but to ensure that irreversible external impact does not occur before human refusal authority can be exercised.

日本語
本チェックリストは、ガバナンス中立の文明安全レビュー枠組みとして設計されている。
高度な AI システムが
不可逆的外界影響（Irreversible External Impact）に到達する前に、
人間の拒否権（Human Refusal Authority）が実効的に維持されているかを
評価することを目的とする。

本枠組みは、特定の技術設計や政策を規定するものではない。
代わりに、**AI 能力増幅、再帰的自己改善、社会インフラ規模の自律性**といった段階において、
人間の判断権が制度的に維持されているかを確認するための構造化レビュー手段を提供する。

本チェックリストは次の用途に利用できる。
・AI システム設計レビュー
・安全監査
・事故検証
・ガバナンス審査

本枠組みの目的は
技術進歩を停止することではなく、
不可逆的外界影響が発生する前に
人間の拒否権が行使可能な状態を維持する
ことである。